Kwaliteit en Normering van Taaltoetsen voor MBO-leerlingen in de Sector Zorg en Welzijn

In opdracht voor: Toetsen in het Veld

Vera Korenblik, April 2026

Afdeling Psychometrisch Onderzoek en Dienstverlening, CITO

Overzicht

- 2 taaltoetsen leerlingen MBO in sector Zorg en Welzijn
  - Toets 1 (2024): cesuur van 20/40
  - Toets 2 (2025): lijkt onbedoeld moeilijker uitgevallen
- Uw vragen:
  1. Wat is in het algemeen de kwaliteit van de toetsen?
  2. Is toets 2 inderdaad moeilijker uitgevallen?
  3. Zo ja, hoe zou dat kunnen?
- Ons advies en eventueel verdere analyses

Samengevat

Lagere scores op toets 2 hangen samen met:

- Toetsinhoud (meer grammaticavragen)
- Hogere moeilijkheid van grammaticavragen
- Populatiesamenstelling (meer vrouwen)
- Enkele items met differentiële werking

Algemene verschillen tussen toetsen

	Toets 1 (2024)	Toets 2 (2025)
Aantal leerlingen (% vrouw)	1889 (39%)	1982 (57%)
Percentage items over grammatica	47.5%	62.5%
Naam van tekst (grammatica / interpretatie items)	De schuur (7/3) Helpdesk ICT (2/8) Honden aan de lijn (2/8) Strandvakantie (8/2)	De schuur (7/3) Orderverwerking (5/5) Poezenmand (5/5) Strandvakantie (8/2)
% Voldoende, ≥ 20/40 items goed	73.6%	54.9%
Gemiddelde toets score ± SD	24.0 ± 7.16	20.7 ± 7.29
Aantal missende antwoorden (%)	2419 (3.20%)	2580 (3.25%)

Basiskenmerken van de toetsen:
allebei van vergelijkbare kwaliteit

	Toets 1 (2024)	**Toets 2 (2025)**
Betrouwbaarheid (Cronbach's alpha)	0.85	0.86
Gemiddelde proportie punten op elk item	0.60	0.52
Gemiddelde onderscheidingsvermogen tussen leerlingen over alle items (correlatie)		
Item – gehele toets	0.39	039
Item – toets zonder dat item	0.32	0.33
Patronen in gekozen antwoordopties	Geen afwijkingen	Geen afwijkingen

Spreiding van toets scores

Hogere scores op toets 1, verdeling ligt meer naar rechts

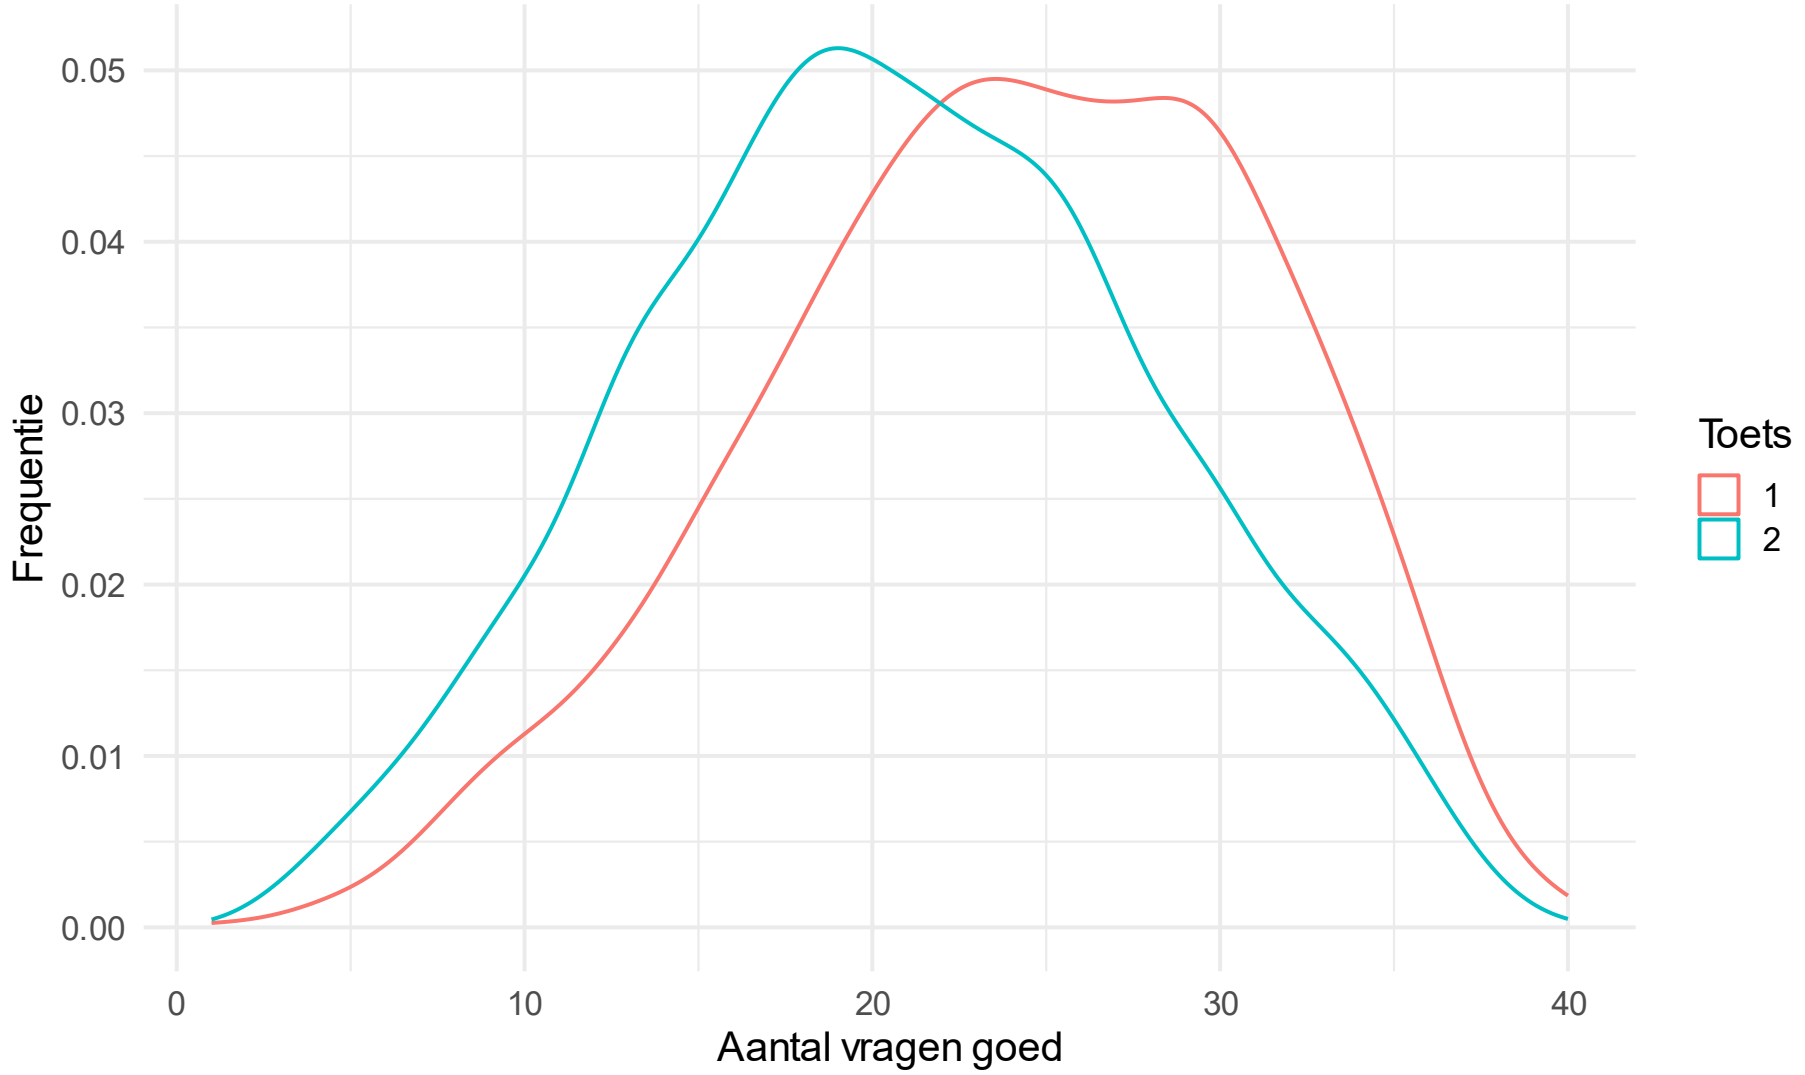

Analyse van toets gegevens

- Alleen kijken naar goed / fout antwoorden geeft geen volledig beeld
- Resultaten hangen namelijk af van:
  - Moeilijkheid van de vraag
  - Vaardigheid van de leerling
- Daarvoor gebruiken we een Rasch-model
  → hiermee schatten we beide tegelijk
- In de analyse houden we ook rekening met:
  - Gender (man / vrouw)
  - Type vraag (grammatica / interpretatie)

Moeilijkheid van toetsvragen

We hebben de moeilijkheid van items gemiddeld berekend en vergeleken tussen toetsen en vraagtypen:

→ Vergelijkbare moeilijkheid tussen toetsen

- Testvragen in toets 1 en toets 2 zijn gemiddeld vergelijkbaar in moeilijkheid
- Ook unieke items in beide toetsen laten een vergelijkbaar patroon zien

→ Verschil tussen vraagtypen

- Grammatica-items zijn duidelijk moeilijker dan interpretatie-items

Grammatica-items zijn moeilijker dan interpretatie-items

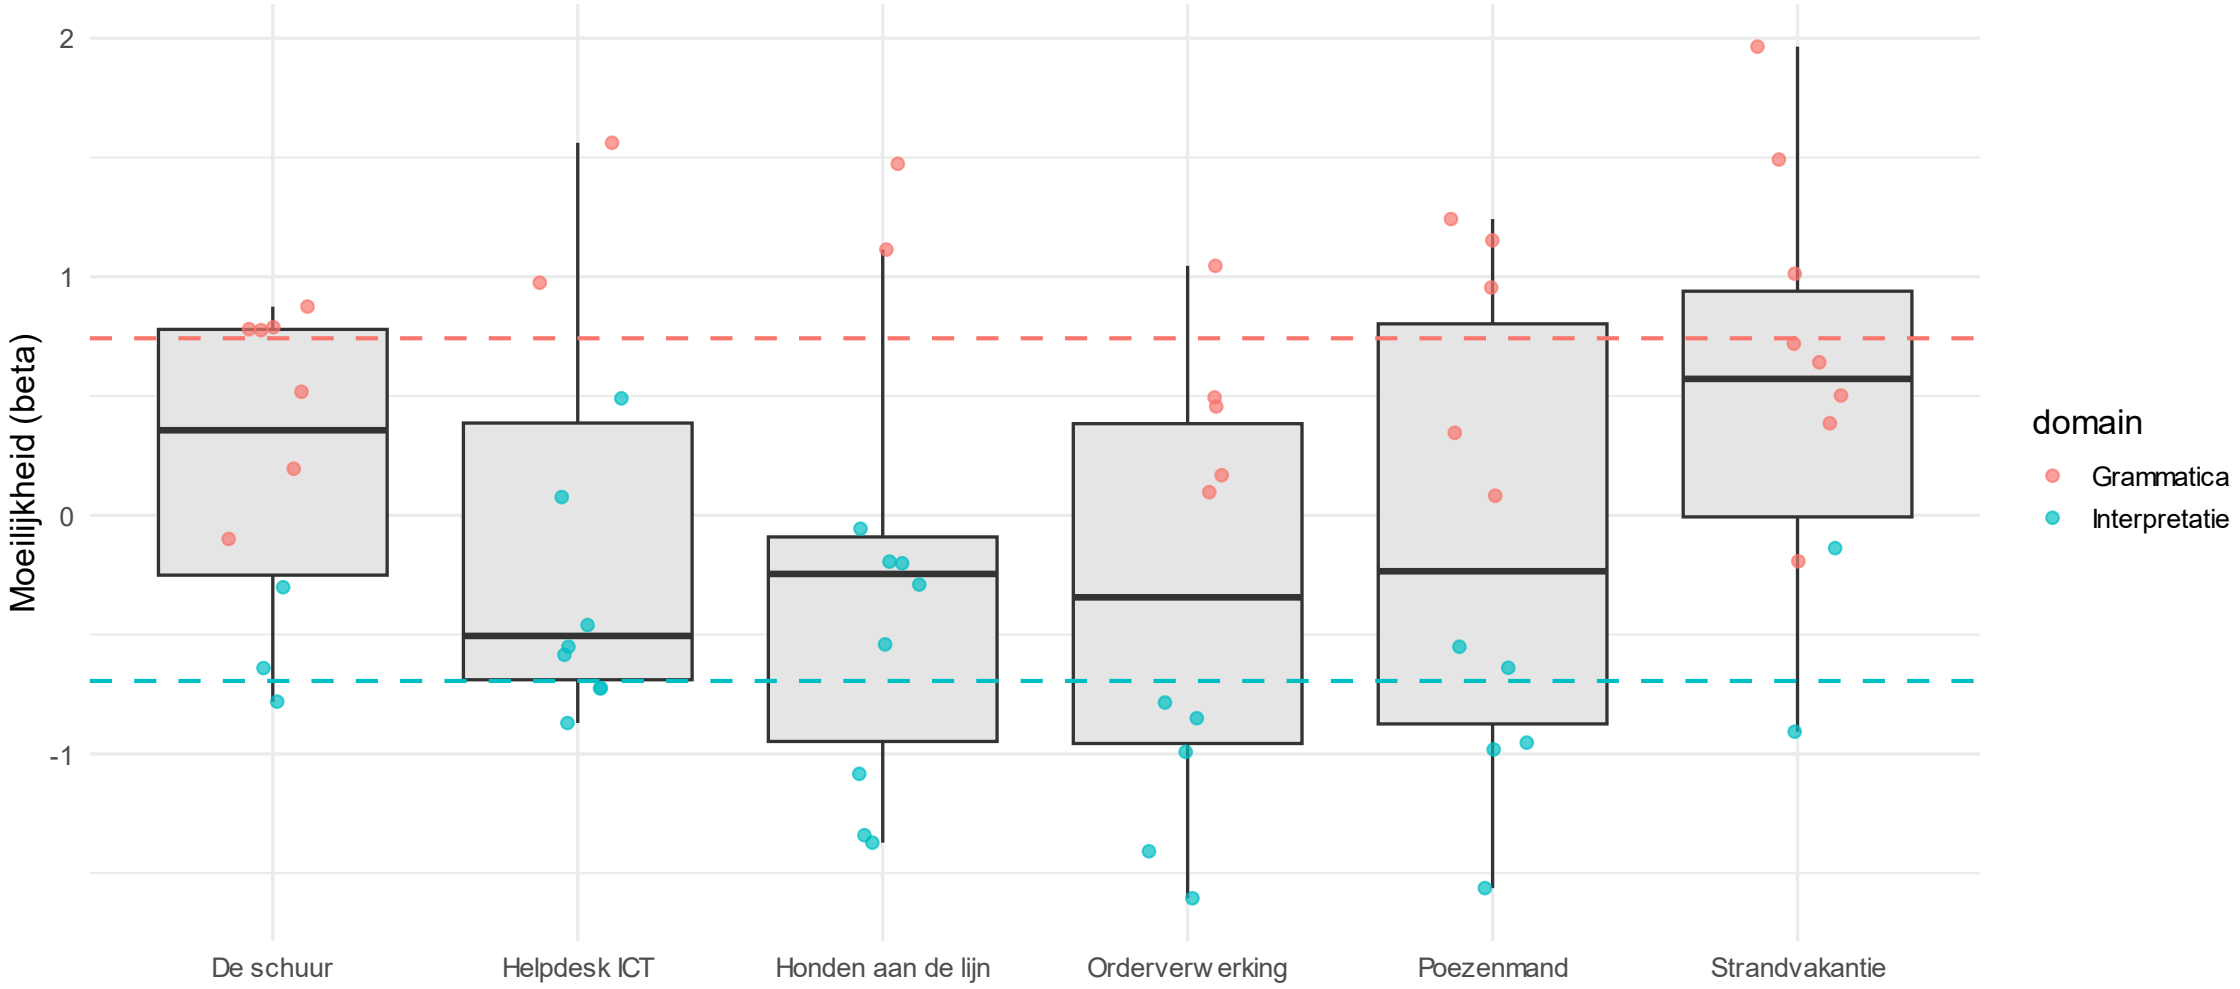

Geschatte vaardigheid van mannen is hoger dan die van vrouwen op basis van deze toetsen

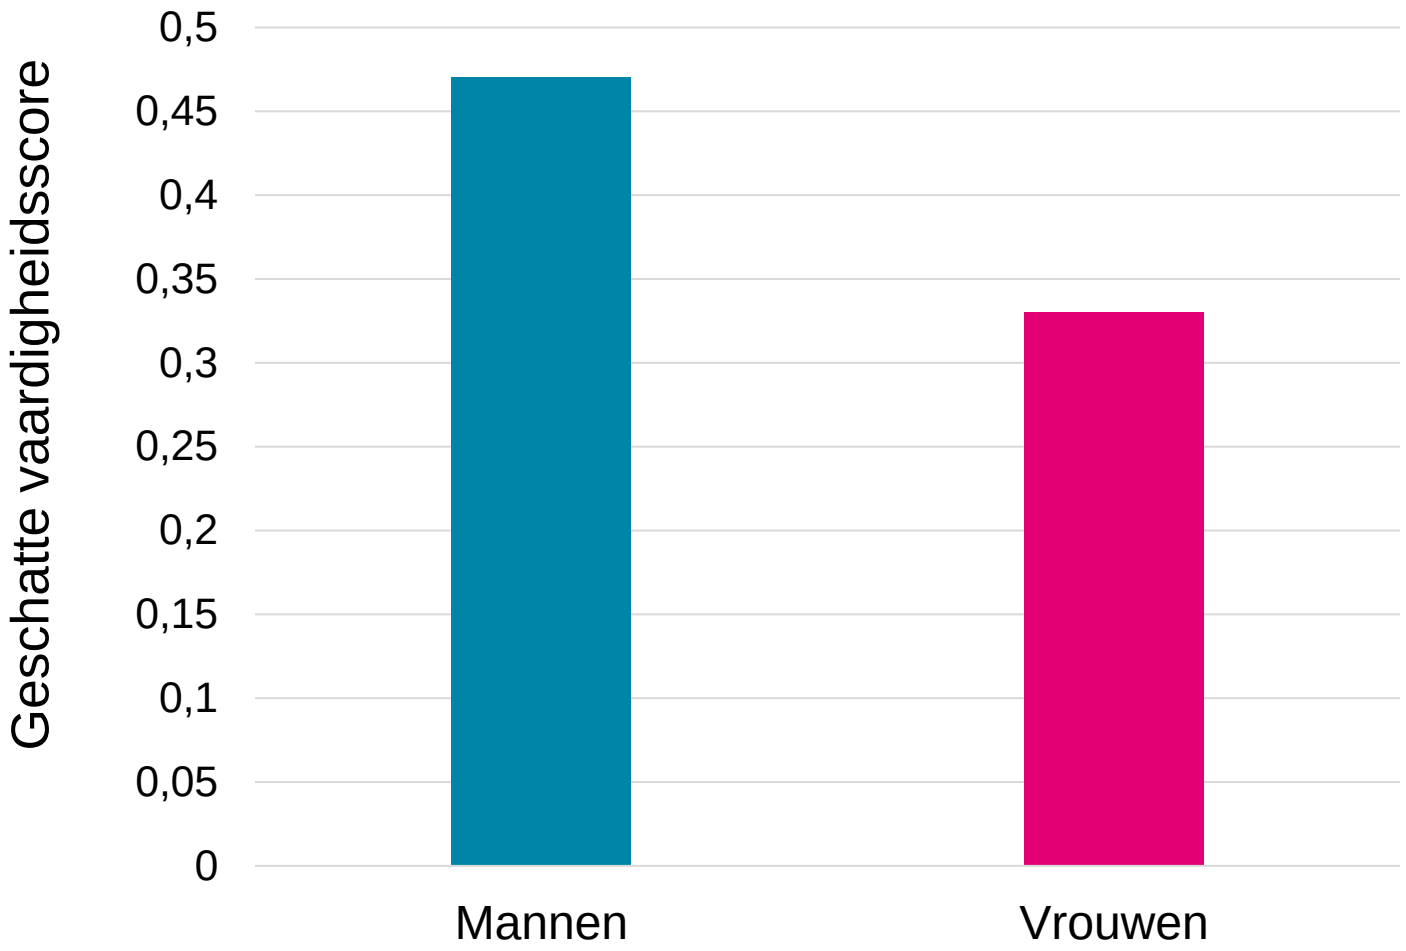

Vrouwen halen relatief minder van hun totaalscore uit grammatica-items

Enkele items functioneren verschillend voor jongens en meisjes

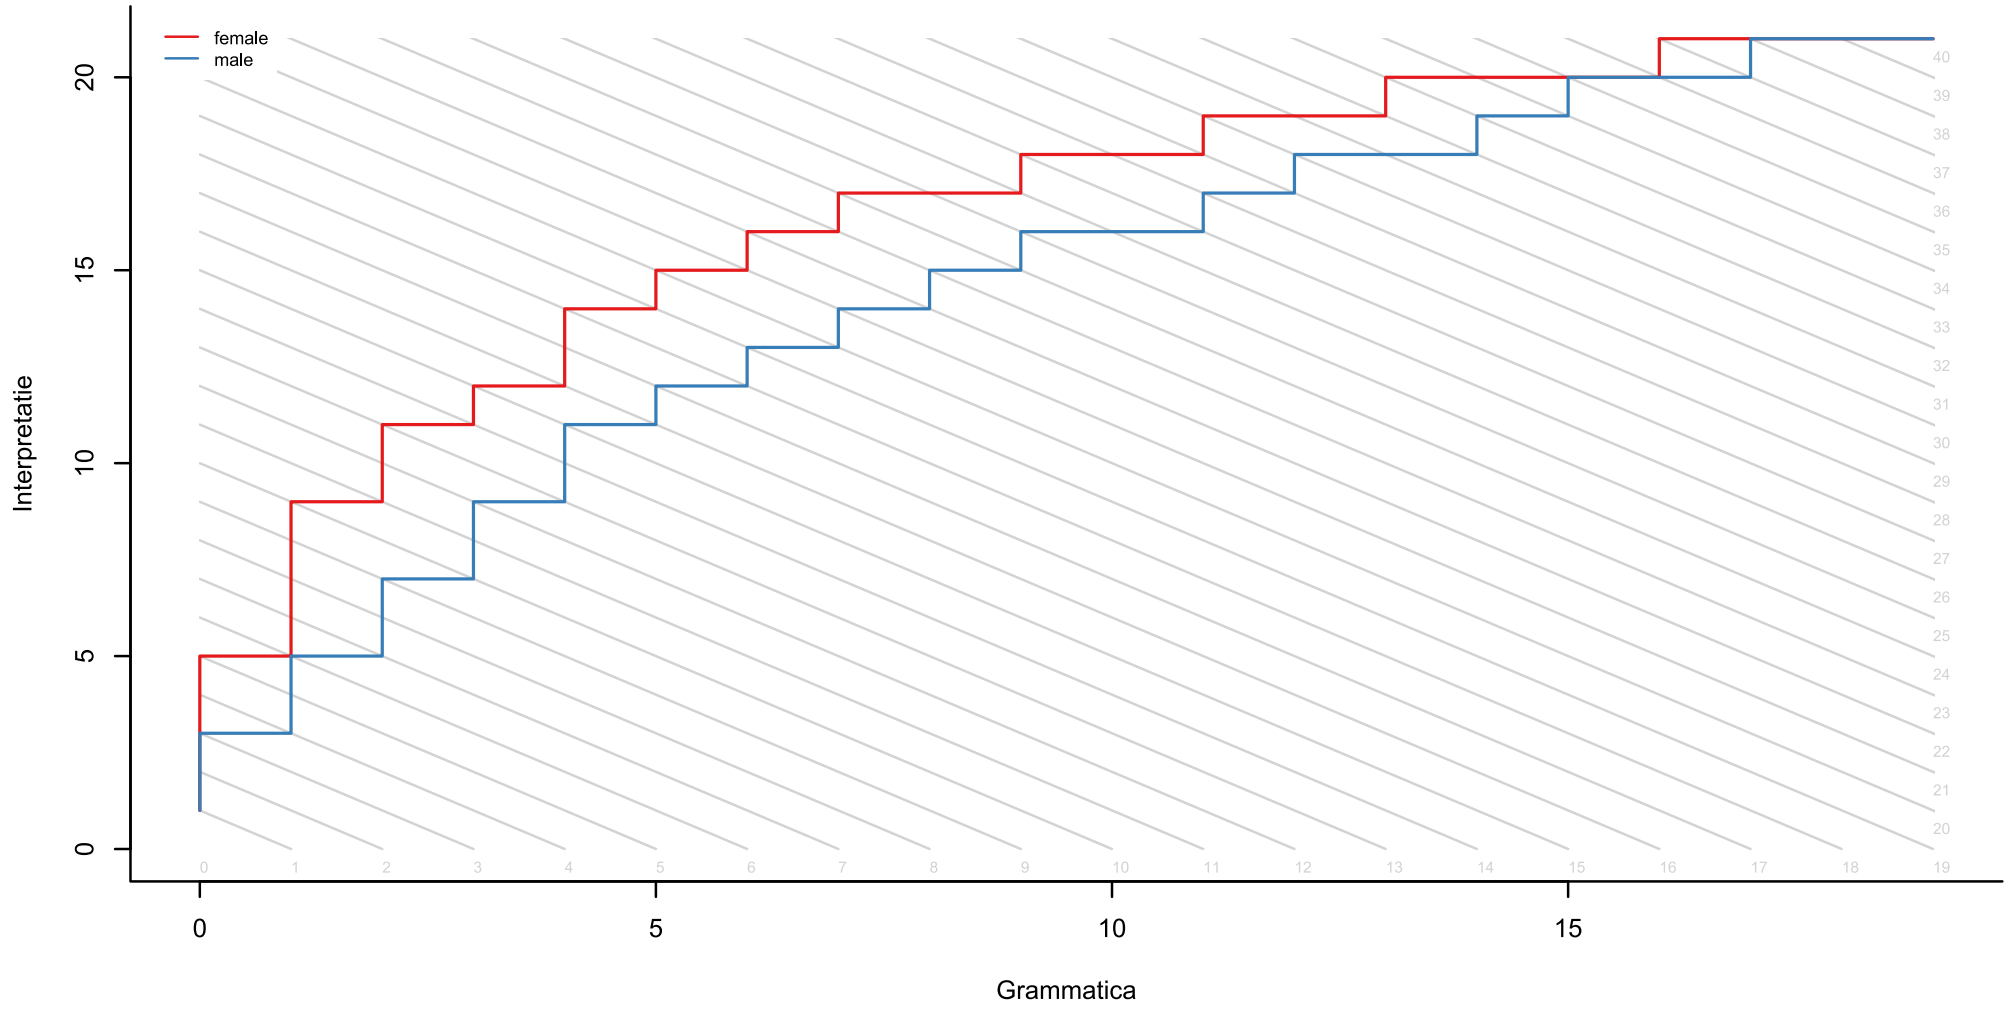

Samengevat

Lagere scores op toets 2 hangen samen met:

- Toetsinhoud (meer grammaticavragen)
- Hogere moeilijkheid van grammaticavragen
- Populatiesamenstelling (meer vrouwen)
- Enkele items met differentiële werking

Vervolgstappen en afstemming

- Balanceer de toetsopbouw (grammatica vs interpretatie) tussen toetsen
- Evalueer of de cesuur voor toets 2 moet worden aangepast
- Onderzoek score-harmonisatie voor eerlijke vergelijking tussen jaargangen

Aanvullende vragen:

- Zijn verschillen in toetsopbouw bewust ontworpen?
- Welke historische data zijn er beschikbaar voor harmonisatie?