Kwaliteit en Normering van Taaltoetsen voor MBO-leerlingen in de Sector Zorg en Welzijn

In opdracht voor: Toetsen in het Veld

Vera Korenblik, April 2026

Afdeling Psychometrisch Onderzoek en Dienstverlening, CITO

Overzicht

- 2 taaltoetsen leerlingen MBO in sector Zorg en Welzijn
  - Toets 1 (2024): cesuur van 20/40
  - Toets 2 (2025): lijkt onbedoeld moeilijker uitgevallen
- Uw vragen:
  1. Wat is in het algemeen de kwaliteit van de toetsen?
  2. Is toets 2 inderdaad moeilijker uitgevallen?
  3. Zo ja, hoe zou dat kunnen?
- Ons advies en eventueel verdere analyses

Samengevat

Lagere scores op toets 2 hangen samen met:

- Toetsinhoud (meer grammaticavragen)
- Hogere moeilijkheid van grammaticavragen
- Populatiesamenstelling (meer vrouwen)
- Enkele items met differentiële werking

Algemene verschillen tussen toetsen

	Toets 1 (2024)	Toets 2 (2025)
Aantal leerlingen (% vrouw)	1889 (39%)	1982 (57%)
Percentage items over grammatica	47.5%	62.5%
Naam van tekst (grammatica / interpretatie items)	De schuur (7/3) Helpdesk ICT (2/8) Honden aan de lijn (2/8) Strandvakantie (8/2)	De schuur (7/3) Orderverwerking (5/5) Poezenmand (5/5) Strandvakantie (8/2)
% Voldoende, ≥ 20/40 items goed	73.6%	54.9%
Gemiddelde toets score ± SD	24.0 ± 7.16	20.7 ± 7.29
Aantal missende antwoorden (%)	2419 (3.20%)	2580 (3.25%)

Basiskenmerken van de toetsen:
allebei van vergelijkbare kwaliteit

	Toets 1 (2024)	**Toets 2 (2025)**
Betrouwbaarheid (Cronbach's alpha)	0.85	0.86
Gemiddelde proportie punten op elk item	0.60	0.52
Gemiddelde onderscheidingsvermogen tussen leerlingen over alle items (correlatie)		
Item – gehele toets [min – max]	0.39 [0.28 – 0.45]	0.39 [0.29 – 0.47]
Item – toets zonder dat item [min – max]	0.32 [0.22 – 0.40]	0.33 [0.24 – 0.41]
Patronen in gekozen antwoordopties	Geen afwijkingen	Geen afwijkingen

Spreiding van toets scores

Hogere scores op toets 1, verdeling ligt meer naar rechts

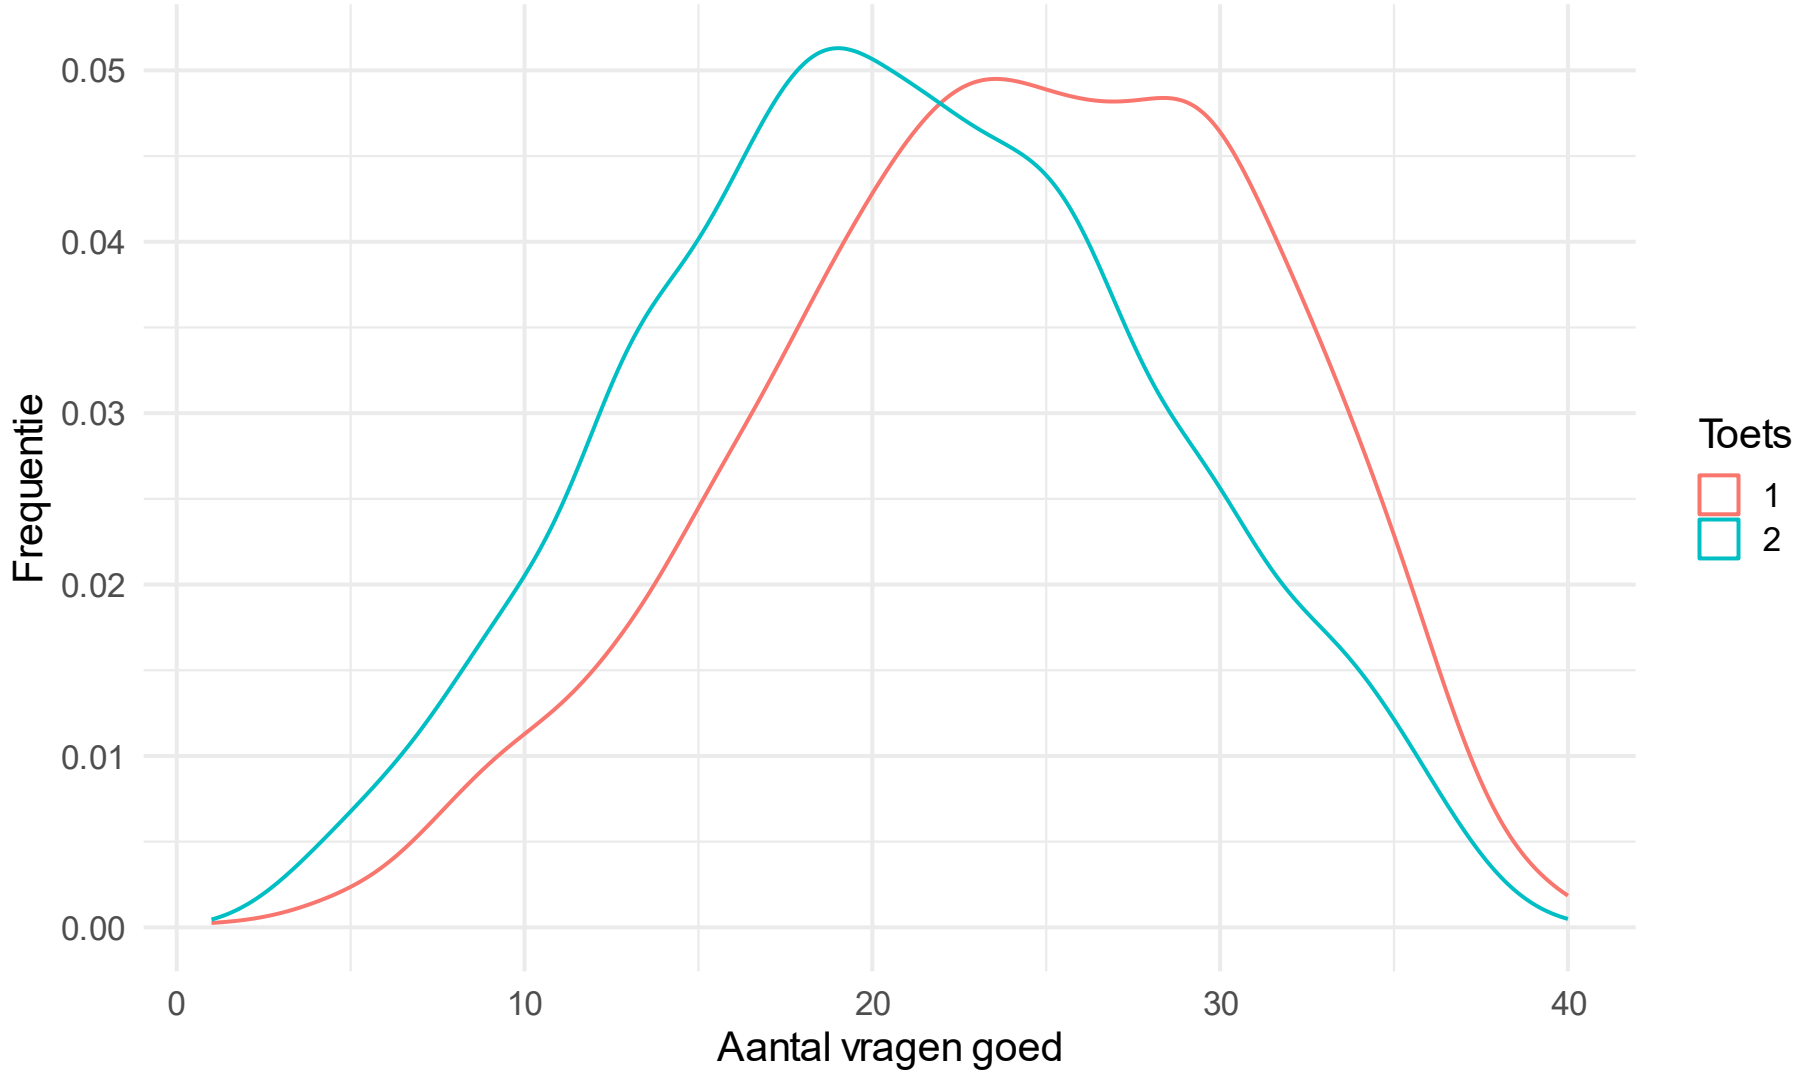

Analyse van toets gegevens

- Alleen kijken naar goed / fout antwoorden geeft geen volledig beeld
- Resultaten hangen namelijk af van:
  - Moeilijkheid van de vraag
  - Vaardigheid van de leerling
- Daarvoor gebruiken we een Rasch-model
  → hiermee schatten we beide tegelijk
- In de analyse houden we ook rekening met:
  - Gender (man / vrouw)
  - Type vraag (grammatica / interpretatie)

Moeilijkheid van toetsvragen

We hebben de moeilijkheid van items gemiddeld berekend en vergeleken tussen toetsen en vraagtypen:

→ Vergelijkbare moeilijkheid tussen toetsen

- Testvragen in toets 1 en toets 2 zijn gemiddeld vergelijkbaar in moeilijkheid
- Ook unieke items in beide toetsen laten een vergelijkbaar patroon zien

→ Verschil tussen vraagtypen

- Grammatica-items zijn duidelijk moeilijker dan interpretatie-items

Grammatica-items zijn moeilijker dan interpretatie-items

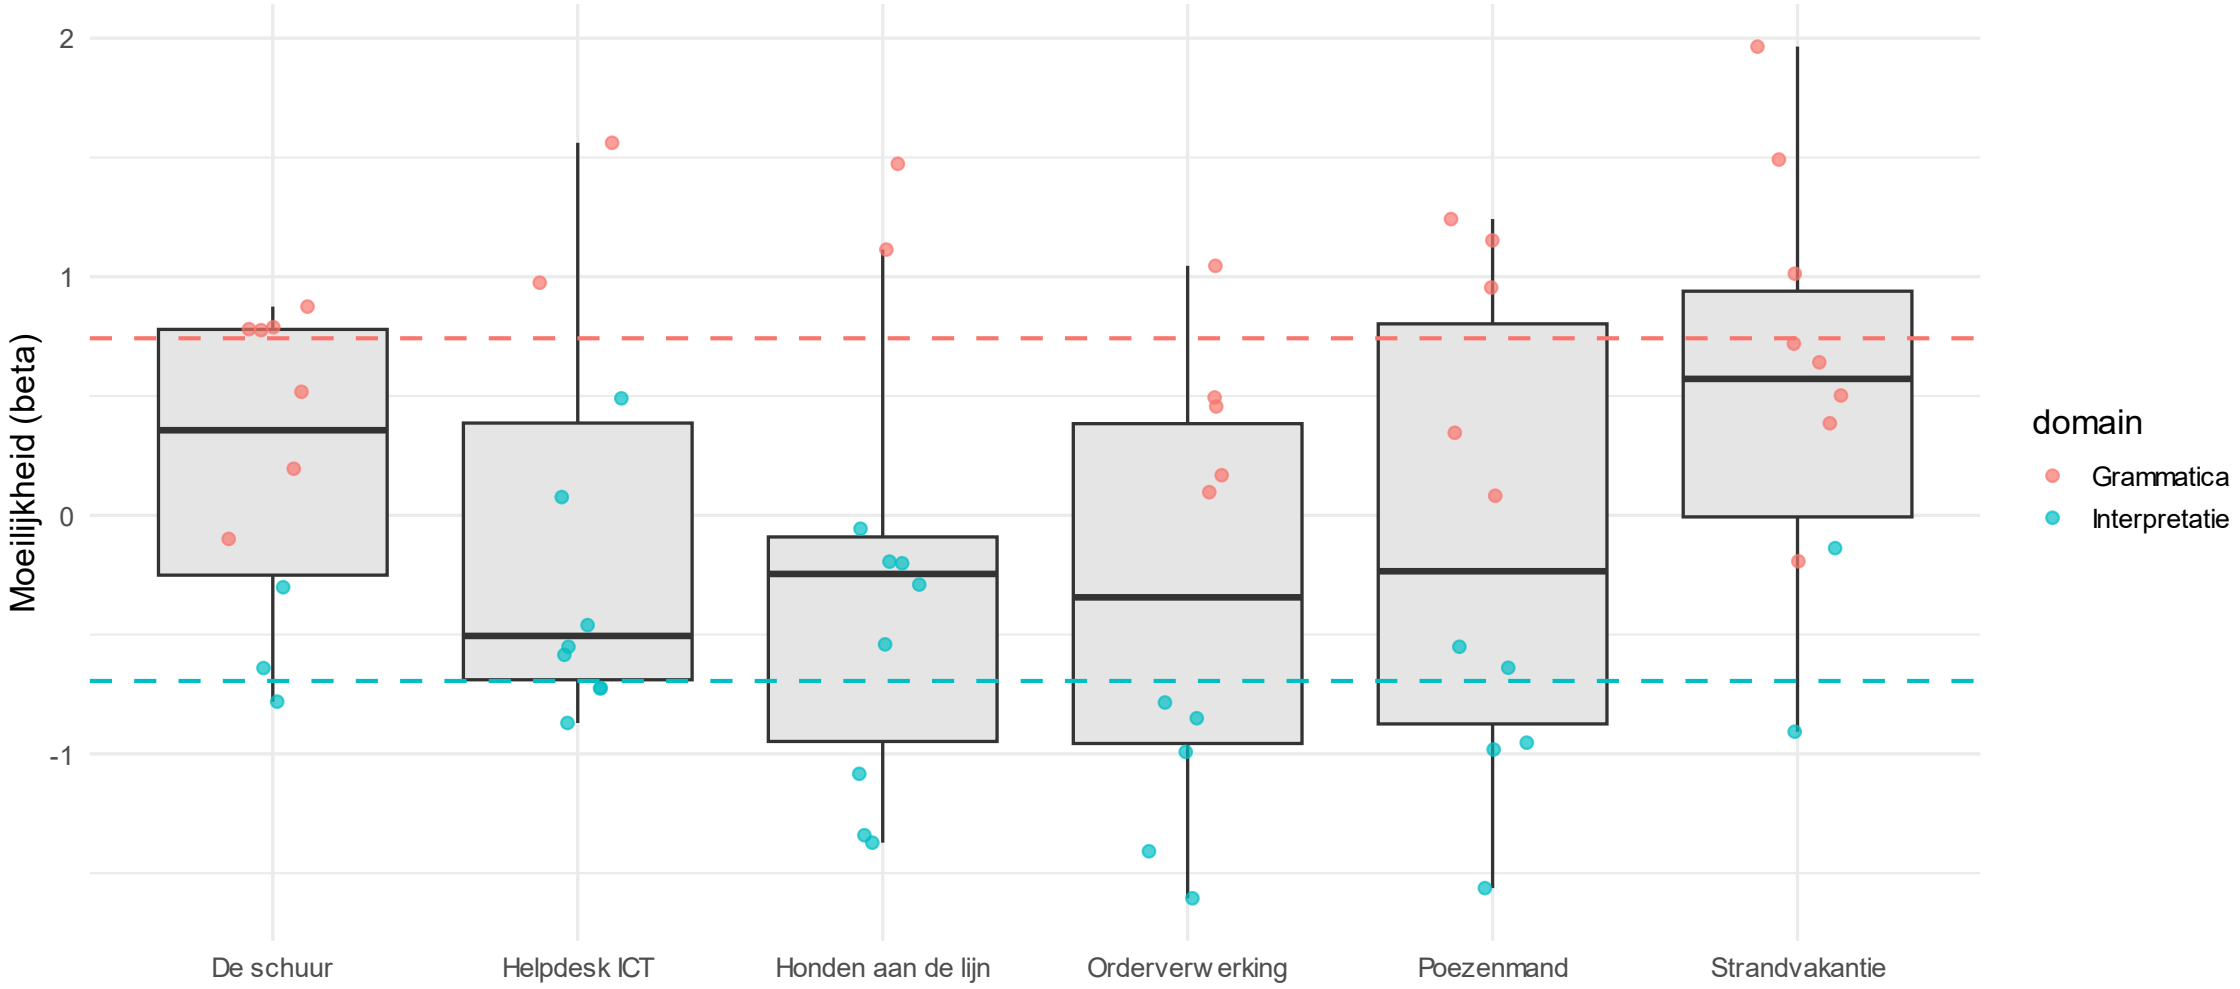

Geschatte vaardigheid van mannen is hoger dan die van vrouwen op basis van deze toetsen

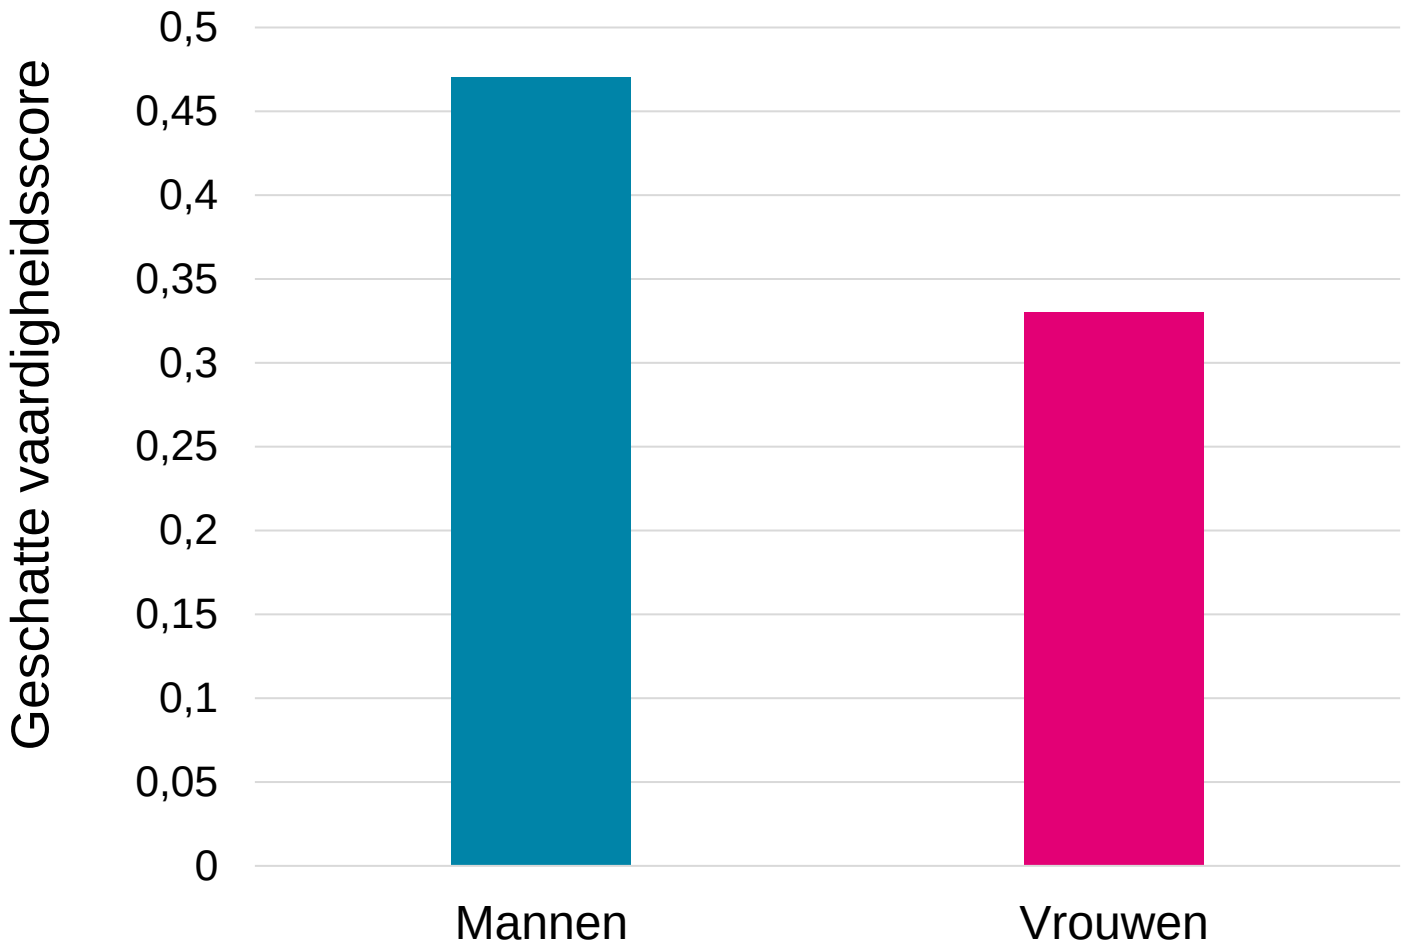

Vrouwen halen relatief minder van hun totaalscore uit grammatica-items

Enkele items functioneren verschillend voor jongens en meisjes

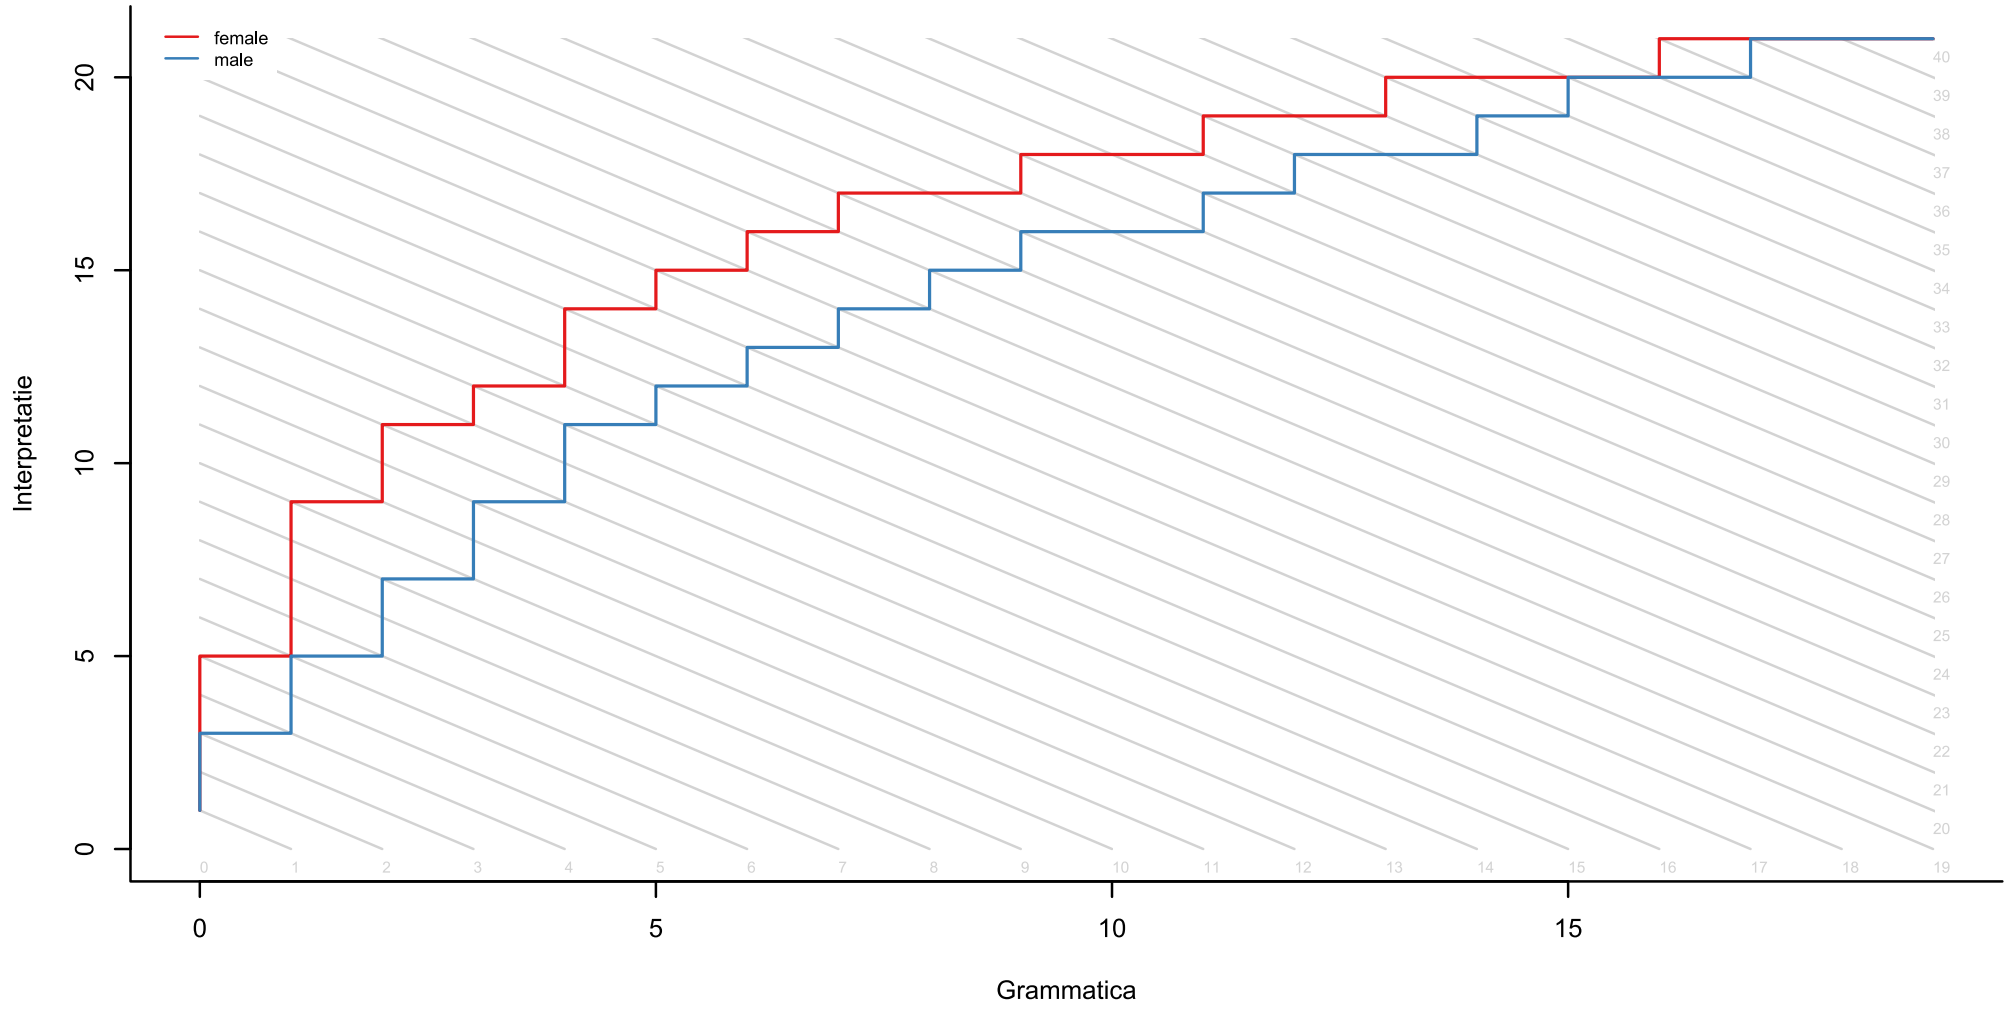

Samengevat

Lagere scores op toets 2 hangen samen met:

- Toetsinhoud (meer grammaticavragen)
- Hogere moeilijkheid van grammaticavragen
- Populatiesamenstelling (meer vrouwen)
- Enkele items met differentiële werking

Vervolgstappen en afstemming

- Balanceer de toetsopbouw (grammatica vs interpretatie) tussen toetsen
- Evalueer of de cesuur voor toets 2 moet worden aangepast
- Onderzoek score-harmonisatie voor eerlijke vergelijking tussen jaargangen

Aanvullende vragen:

- Zijn verschillen in toetsopbouw bewust ontworpen?
- Welke historische data zijn er beschikbaar voor harmonisatie?